# Práctica 7: Modelo de Ising e Histéresis

Jorge Acebes Hernández Computación Avanzada Código - GitHub

## 1. Introducción

El modelo de Ising bidimensional constituye uno de los paradigmas fundamentales en la física estadística para el estudio de transiciones de fase y fenómenos críticos. Este sistema describe la dinámica de espines magnéticos interactuantes en una red discreta, permitiendo modelar el ferromagnetismo a nivel microscópico.

El objetivo principal de este trabajo es simular computacionalmente el modelo de Ising 2D en ausencia de campo magnético externo, enfocando el análisis en la transición de fase continua que ocurre a la temperatura crítica ($T_c$). El alcance computacional abarca el estudio de la energía, la capacidad calorífica, la magnetización (como parámetro de orden del sistema) y la susceptibilidad magnética. Adicionalmente, se busca validar mediante un análisis de escalado de tamaño finito (*finite-size scaling*) las divergencias teóricas de la capacidad calorífica y la susceptibilidad en el límite termodinámico. Posteriormente, el estudio se amplía mediante la introducción de un campo magnético externo, lo que permite explorar el régimen de rotura explícita de simetría y caracterizar la respuesta del sistema a través de su ciclo de histéresis magnética. Por último, se introduce un enfoque basado en aprendizaje automático (*Machine Learning*), empleando un modelo de regresión logística para automatizar la clasificación del sistema en sus fases ordenada (ferromagnética) y desordenada (paramagnética) a partir de sus observables termodinámicos.

## 2. Marco Teórico

El sistema se describe mediante un conjunto de variables de espín $s_i \in \{-1, +1\}$ dispuestas en una red cuadrada bidimensional de lado $L$, con $N = L^2$ sitios. El hamiltoniano del sistema, considerando interacciones a primeros vecinos y la interacción Zeeman con un campo magnético externo $H$, viene dado por:

$$\mathcal{H} = -J \sum_{\langle i,j \rangle} s_i s_j - \mu H \sum_{i=1}^{N} s_i \tag{1}$$

donde $J > 0$ es la constante de acoplamiento ferromagnético y $\mu$ es el momento magnético de cada espín. El parámetro de orden macroscópico, la magnetización total de una configuración, se define como la suma de todos los espines del sistema:

$$M = \sum_{i=1}^{N} s_i \tag{2}$$

En el caso particular de ausencia de campo magnético ($H = 0$), la solución analítica exacta obtenida por Onsager (1944) predice una transición de fase continua a una temperatura crítica $T_c$ dada por:

$$k_B T_c = \frac{2J}{\ln(1 + \sqrt{2})} \approx 2.269J \tag{3}$$

adoptando un sistema de unidades naturales donde la constante de Boltzmann es $k_B = 1$.

En simulaciones de tamaño finito y en ausencia de un campo externo que rompa la simetría, el sistema puede transicionar globalmente entre estados de magnetización positiva y negativa. Para evitar que el promedio térmico se anule artificialmente por debajo de $T_c$, se evalúa el valor esperado del valor absoluto de la magnetización por espín:

$$m = \frac{\langle |M| \rangle}{N} \tag{4}$$

Las fluctuaciones de la energía interna y de la magnetización determinan, a través del teorema de fluctuación-disipación, la capacidad calorífica $C$ y la susceptibilidad magnética $\chi$, respectivamente:

$$\frac{C}{N} = \frac{\langle E^2 \rangle - \langle E \rangle^2}{N k_B T^2}, \qquad \frac{\chi}{N} = \frac{\langle M^2 \rangle - \langle |M| \rangle^2}{N k_B T} \tag{5}$$

En la vecindad de $T_c$, la teoría de escalado de tamaño finito predice que estas magnitudes divergen. La capacidad calorífica máxima diverge logarítmicamente, mientras que la susceptibilidad máxima escala según una ley de potencias:

$$\frac{C_{\text{máx}}}{N} \propto \ln L, \qquad \frac{\chi_{\text{máx}}}{N} \propto L^{\gamma/\nu} \tag{6}$$

donde $\nu = 1$ es el exponente asociado a la longitud de correlación y $\gamma = 7/4$ es el exponente de la susceptibilidad magnética. De esta manera, al aplicar logaritmos, esta relación se linealiza para su comprobación empírica como:

$$\ln\left(\frac{\chi_{\text{máx}}}{N}\right) \propto 1.75 \ln L + \text{cte} \tag{7}$$

Por otro lado, cuando el sistema opera por debajo de la temperatura crítica ($T < T_c$) en presencia de un campo magnético variable, presenta una fuerte dependencia de su historia térmica y magnética debido a la aparición de estados metaestables. Al someter al material a un campo magnético cíclico ($H \to -H \to H$), el parámetro de orden no sigue una trayectoria termodinámica reversible, sino que describe un ciclo de histéresis.

Finalmente, la identificación de la transición termodinámica puede formularse matemáticamente como un problema de clasificación binaria. Las variables macroscópicas estocásticas del sistema (energía $E$, magnetización $M$ y susceptibilidad $\chi$) actúan como vectores de características (*features*). Esto permite a un algoritmo de regresión logística estimar la probabilidad posterior de que una configuración pertenezca a la fase desordenada paramagnética ($T > T_c$).

## 3. Marco Computacional

La evaluación de los observables termodinámicos requiere muestrear el espacio de configuraciones, cuya dimensión es $2^N$. Para sortear esta intratabilidad computacional, se implementa el método de Monte Carlo acoplado al algoritmo de Metropolis, generando una cadena de Markov que converge a la distribución de Boltzmann.

El algoritmo selecciona aleatoriamente un espín $s_i$ y evalúa la diferencia de energía $\Delta E$ asociada a su inversión ($s_i \to -s_i$). Si $\Delta E \leq 0$, el cambio se acepta; si $\Delta E > 0$, se acepta con una probabilidad $p = \exp(-\Delta E/T)$. Para mitigar los efectos de borde, se aplican condiciones de contorno periódicas.

```python
@njit
def paso_metropolis(red, T):
    L = red.shape[0]
    for _ in range(L * L):
        i = np.random.randint(L)
        j = np.random.randint(L)
        s = red[i, j]

        # Condiciones de contorno periodicas
        vecinos = red[(i+1)%L, j] + red[i, (j+1)%L] + red[(i-1)%L, j] + red[i,
   (j-1)%L]
        dE = 2.0 * J * s * vecinos

        if dE <= 0 or np.random.rand() < np.exp(-dE / T):
            red[i, j] = -s
    return red
```

Código 1: Implementación del paso de Metropolis optimizado con Numba.

La presencia del campo magnético modifica la variación de energía local al intentar invertir un espín $s_i$, resultando en $\Delta E = 2s_i(J\sum s_j + \mu H)$. Para la evaluación de la histéresis, se implementó una rutina específica que inicializa la red en un estado completamente ordenado (emulando muy baja temperatura). Posteriormente, se realiza un barrido paramétrico sobre el campo magnético $H$. Es fundamental computacionalmente que el microestado final de un paso de $H$ sirva como condición inicial del siguiente, preservando así la memoria magnética que da origen al ciclo.

Cabe destacar que, dado que Python estándar es ineficiente en bucles anidados intensivos, se recurre a la compilación *Just-In-Time* (JIT) mediante la librería `Numba` (`@njit`). Esto reduce la complejidad temporal de la ejecución de forma drástica, permitiendo simular redes de hasta $L = 40$ con 10000 pasos de medida en un tiempo computacional aceptable. El sistema se termaliza durante 2000 pasos antes de comenzar la recolección de estadísticas energéticas para el cálculo de fluctuaciones.

Una vez obtenidas las series termodinámicas para la red de mayor tamaño ($L = 40$), se procede a la etapa de aprendizaje automático. Se define una variable objetivo binaria $y$ que toma el valor 1 si la temperatura de simulación supera la teórica ($T > T_c$, fase desordenada) y 0 en caso contrario.

```python
pipe = Pipeline([
    ("scaler", StandardScaler()),
    ("clf", LogisticRegression(max_iter=2000))
])

X_train, X_test, y_train, y_test, T_train, T_test = train_test_split(
    X, y, T_rango, test_size=0.25, random_state=0, stratify=y
)
pipe.fit(X_train, y_train)
y_pred = pipe.predict(X_test)
```

Código 2: Pipeline de clasificación con Scikit-Learn.

Los predictores $\mathbf{X} = (M, E, \chi)$ se normalizan restando la media y dividiendo por la desviación típica (`StandardScaler`). Los datos se dividen en un 75 % para entrenamiento y un 25 % para prueba, utilizando

un muestreo estratificado (`stratify=y`) para garantizar que la proporción de datos en fases ordenadas y desordenadas sea idéntica en ambos conjuntos, previniendo sesgos en el entrenamiento del clasificador.

# 4. Resultados y Análisis

## 4.1. Transición de Fase y Criticidad

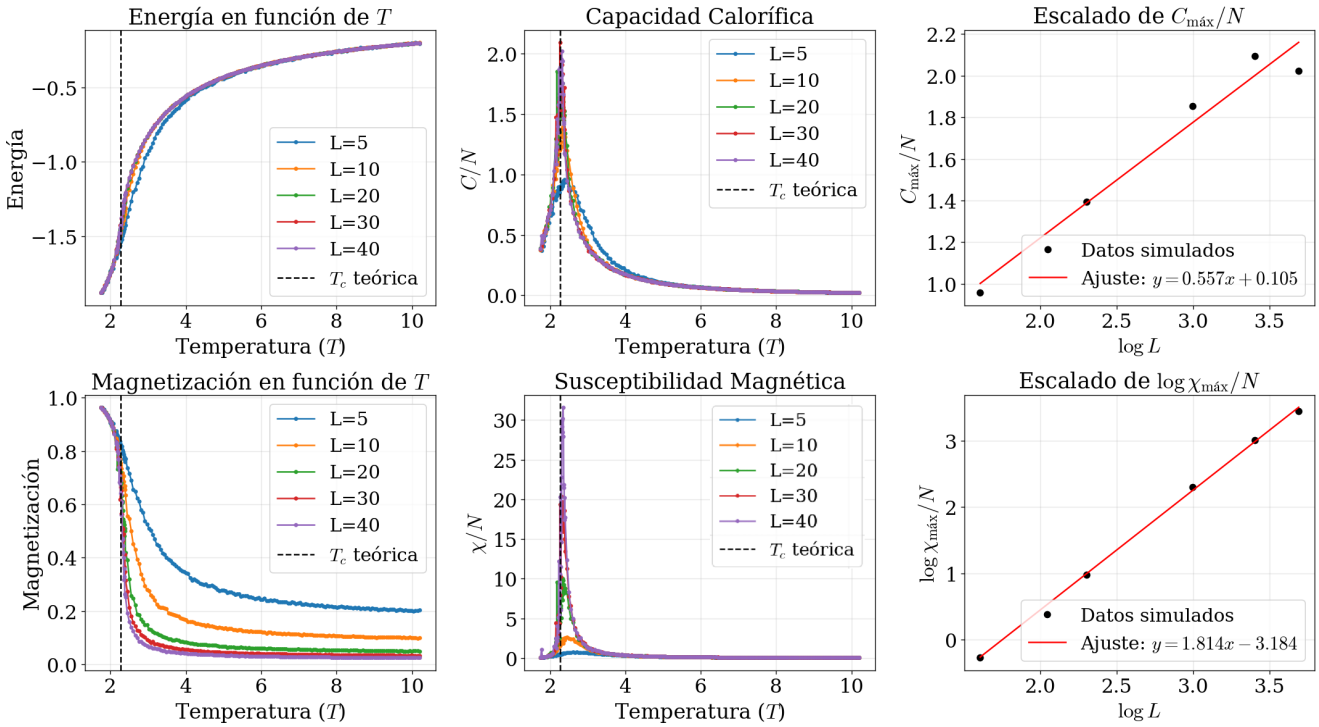


Figura 1: Evolución de observables termodinámicas (Energía, Magnetización, Capacidad Calorífica $C/N$ y Susceptibilidad $\chi/N$) frente a la temperatura $T$ para redes de espines de tamaño $L \in \{5, 10, 20, 30, 40\}$. A la derecha, ajustes de escalado finito sobre los valores máximos.

La Figura 1 expone las métricas promediadas tras las simulaciones de Monte Carlo. La energía del sistema registra un punto de inflexión alrededor del dominio $T \in [2.15, 2.4]$, provocando un máximo agudo en la capacidad calorífica $C/N$. En sincronía, la magnetización decae marcadamente desde 1.0 hacia 0.0, generando una divergencia correlativa en la susceptibilidad magnética $\chi/N$. Las gráficas de escalado demuestran una dependencia estricta con el tamaño del retículo, resultando en un ajuste empírico $C_{\text{máx}}/N = 0.557 \ln L + 0.105$ y una progresión lineal en escala log-log para la susceptibilidad con ecuación $\ln(\chi_{\text{máx}}/N) = 1.814 \ln L - 3.184$.

Estos resultados atestiguan una transición de fase continua (segundo orden) característica del modelo de Ising bidimensional. Las singularidades convergen exactamente en la temperatura crítica teórica de Onsager, $T_c \approx 2.269$, delimitando la rotura espontánea de simetría continua hacia un estado paramagnético. En cuanto a la linealidad observada en los diagramas de dispersión de escalado de tamaño finito, estos corroboran la dependencia funcional descrita en las Expresiones 6 y 7. En particular, la pendiente en la susceptibilidad representa la relación $\gamma/\nu \approx 1.814$, arrojando un error relativo del $\epsilon = 3.66\,\%$ frente al valor teórico ($\gamma/\nu = 1.75$). Esto es explicable por la persistencia de correcciones de tamaño finito de orden superior para $L \leq 40$.

## 4.2. Dinámica de Histéresis

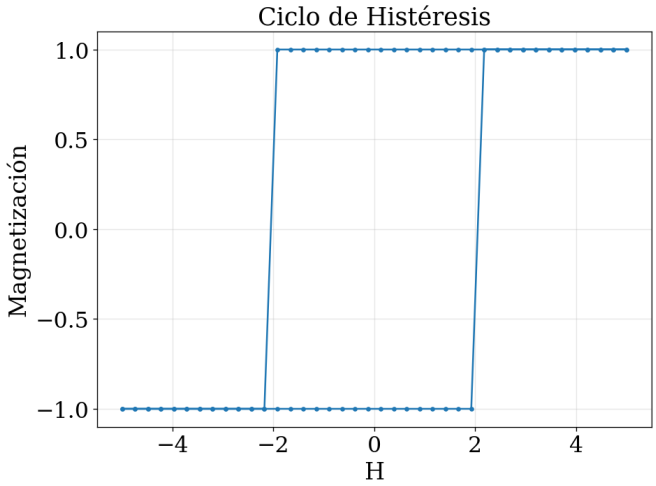


Figura 2: Curva del ciclo de histéresis demostrando la respuesta magnética del sistema frente a un gradiente de campo externo ($H$) bajo condiciones isotérmicas ($T = 0.25 < T_c$).

Tal como ilustra la Figura 2, la iteración escalar del campo $H \in [-5, 5]$ a baja temperatura, $T = 0.25$, traza una morfología de histéresis fundamentalmente cuadrada. Este ciclo visibiliza de forma gráfica el principio de memoria magnética y metaestabilidad asociado a sistemas ordenados bajo el dominio $T < T_c$. La inercia para mantener su vector de alineación colectivo (pese a retirar $H$) deriva intrínsecamente del acoplamiento energético ferromagnético dictado por la constante de interacción intermolecular $J > 0$. El paralelismo agudo en las franjas de conmutación ($\pm 2.0$) reafirma que bajo esa condición de temperatura, la reinversión no sigue un mecanismo suave de nucleación, sino que actúa como una transición de primer orden (efecto de avalancha estructural) que se detona instantáneamente tan pronto como el trabajo del Hamiltoniano de Zeeman, denotado como $\mathcal{H}_{Zeeman} = -H \sum s_i$, logra anular competitivamente la protección energética impuesta por la simetría ferroica preexistente.

## 4.3. Clasificación de Fases mediante Regresión Logística

La Figura 3 mapea la topología predictiva evaluada sobre el conjunto de prueba (*test*). La distribución estocástica conforma una función sigmoide altamente definida. En el régimen de baja temperatura ($T \ll T_c$), la asignación a la clase desordenada es residual ($P \approx 0.0$). A altas temperaturas ($T > 2.4$), la certeza de desorden se maximiza iterativamente ($P \approx 1.0$). El umbral de decisión matemática ($P = 0.5$) se asienta sobre una abscisa coincidente con $T \approx 2.27$, acotado en un rango de incerteza muy estrecho. Este desempeño prácticamente ideal queda matemáticamente respaldado por la matriz de confusión obtenida:

$$C = \begin{pmatrix} TP & FP \\ FN & TN \end{pmatrix} = \begin{pmatrix} 7 & 0 \\ 1 & 41 \end{pmatrix} \tag{8}$$

donde $TP, FP, FN, TN$ corresponden a verdadero positivo, falso positivo, falso negativo, verdadero negativo, respectivamente.

La estructura casi diagonal observada tiene asociada un *accuracy* $= 0.98$, recayendo casi la totalidad de las predicciones en los Verdaderos Positivos y Verdaderos Negativos, con una pequeña tasa de error. Este resultado refleja que la trivialidad algorítmica de este ejercicio en particular era muy alta. Al inyectar

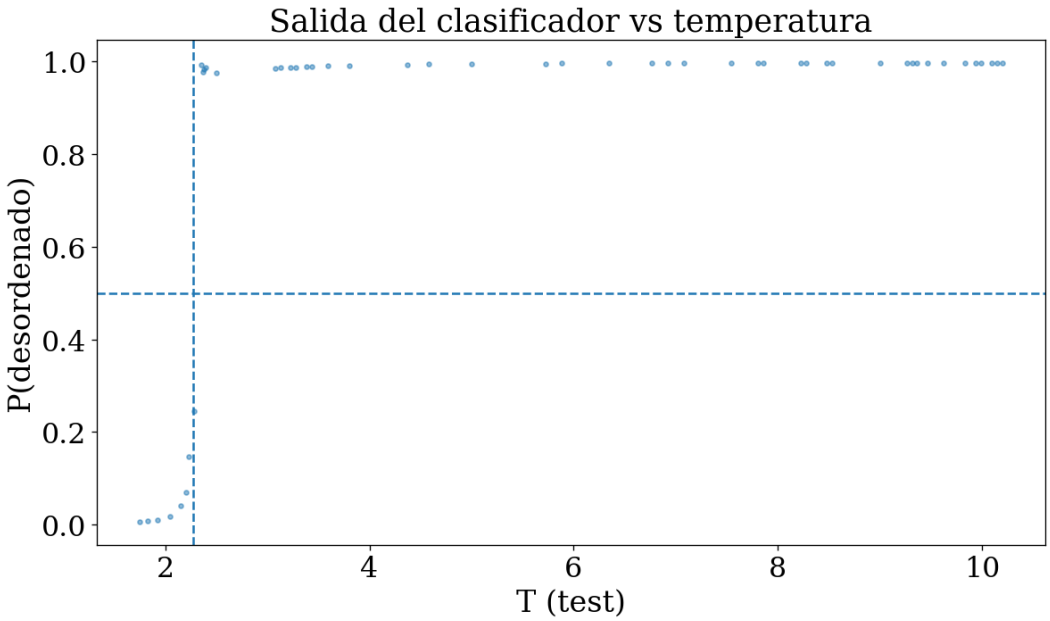


Figura 3: Respuesta estocástica del modelo clasificador, ilustrando la probabilidad predicha de estado paramagnético (desordenado) en función de la variable intensiva del entorno ($T$).

como características de entrada las magnitudes macroscópicas directas del sistema $(M, E, \chi)$, el problema posee una complejidad determinista que induce a una solución analíticamente trivial para una regresión logística: el modelo simplemente optimiza un umbral para el decaimiento abrupto de la magnetización (el parámetro de orden ya resuelto por la simulación). En consecuencia, este planteamiento no pretende revelar nueva física, sino que se establece como un modelo introductorio y pedagógico, diseñado estrictamente para demostrar de forma clara y visual cómo se pueden integrar las herramientas de *Machine Learning* en la caracterización de problemas de física y transiciones de fase.

## 5. Conclusiones

El desarrollo computacional de este trabajo ha permitido simular y caracterizar con alta fidelidad la transición de fase ferromagnética-paramagnética del modelo de Ising bidimensional. Mediante el algoritmo de Monte Carlo, se ha verificado la rotura espontánea de simetría en la vecindad de la temperatura crítica de Onsager ($T_c \approx 2.269$). Además, el análisis de escalado de tamaño finito (*finite-size scaling*) ha corroborado las divergencias teóricas con notable precisión, obteniendo un cociente de exponentes críticos $\gamma/\nu \approx 1.814$.

Por otro lado, la incorporación del campo magnético externo ha modelado con éxito la dinámica fuera del equilibrio termodinámico reversible. La simulación del ciclo de histéresis en el régimen frío ($T = 0.25$) reproduce la memoria magnética y la metaestabilidad del material, evidenciando cómo la reinversión estructural opera como una transición de primer orden desencadenada abruptamente por la competencia entre la interacción ferromagnética y el Hamiltoniano de Zeeman.

Finalmente, la integración de técnicas de aprendizaje automático ha demostrado la viabilidad operativa de los modelos de clasificación para trazar fronteras de fases termodinámicas. Aunque la regresión logística aplicada sobre observables macroscópicos precalculados $(M, E, \chi)$ reduce el problema a una optimización analíticamente trivial, el clasificador alcanzó una exactitud del 98 %, localizando el umbral crítico de

forma robusta. Este ejercicio pedagógico sienta una base computacional sólida para futuras líneas de investigación, justificando la transición hacia arquitecturas de aprendizaje profundo (*Deep Learning*) alimentadas con microestados espaciales crudos, cuyo objetivo será el descubrimiento de nuevas fases en sistemas donde el parámetro de orden sea desconocido *a priori*.

## Bibliografía


Nicholas J. Giordano and Hisao Nakanishi. *Computational Physics*. Pearson Education Inc., 2nd edition, 2006.

Mark E. J. Newman. *Computational Physics*. CreateSpace Independent Publishing Platform, 2012.

Lars Onsager. Crystal statistics. i. a two-dimensional model with an order-disorder transition. *Phys. Rev.*, 65:117–149, Feb 1944. doi: 10.1103/PhysRev.65.117. URL https://link.aps.org/doi/10.1103/PhysRev.65.117.